

Práctica de Deep Learning

Alumno: Fernando Amalfitano

Predicción del nivel de engagement mediante un modelo multimodal

El objetivo de esta práctica es desarrollar un modelo de Deep Learning capaz de predecir el nivel de engagement de un Punto de Interés (POI) utilizando información visual y metadatos asociados a cada elemento del conjunto de datos.

Para ello se ha implementado un modelo multimodal que combina las características extraídas de una imagen mediante una red neuronal convolucional preentrenada con información tabular procedente del archivo de metadatos.

- Descripción del conjunto de datos

El conjunto de datos está formado por:

- Un archivo CSV con la información de cada POI.
- Una imagen principal asociada a cada registro.

Los metadatos utilizados en el modelo son:

- tier
- locationLon
- locationLat
- xps
- num_categories
- num_tags
- description_length

Además, el dataset contiene diferentes métricas de interacción (Likes, Bookmarks, Visits y Dislikes), utilizadas para construir la variable objetivo.

- Preprocesamiento de los datos

En primer lugar se generó la ruta completa de cada imagen para facilitar su carga desde PyTorch.

Posteriormente se creó una variable denominada **engagement_score**, obtenida a partir de una combinación ponderada de las métricas de interacción. Para evitar que unas variables tuvieran más peso que otras debido a su escala, todas ellas fueron normalizadas mediante MinMaxScaler.

La puntuación de engagement se calculó mediante la siguiente expresión:

- 40 % Likes
- 30 % Bookmarks
- 20 % Visits
- -10 % Dislikes

Finalmente se creó una variable binaria denominada “**y**”, donde:

- $y = 1$ representa un engagement superior a la mediana.
- $y = 0$ representa un engagement inferior o igual a la mediana.

También se realizó una normalización de los metadatos empleados por la red neuronal.

- División del conjunto de datos

El conjunto de datos se dividió en tres subconjuntos:

- 70 % para entrenamiento.
- 15 % para validación.
- 15 % para prueba.

Esta división permite entrenar el modelo y evaluar posteriormente su capacidad de generalización.

- Arquitectura del modelo

El modelo desarrollado sigue un enfoque multimodal compuesto por dos ramas.

Extracción de características visuales

Para el procesamiento de imágenes se utilizó EfficientNet-B0 preentrenada sobre ImageNet.

La última capa clasificadora fue eliminada para utilizar únicamente el extractor de características visuales, obteniendo un vector de 1280 características por imagen.

Durante el entrenamiento los pesos de EfficientNet permanecieron congelados (Transfer Learning).

Red neuronal para metadatos

Los metadatos se procesaron mediante una red neuronal completamente conectada formada por:

- Capa lineal de entrada.
- Función de activación ReLU.
- Capa Dropout para reducir el sobreajuste.
- Segunda capa lineal.

- Nueva activación ReLU.

Fusión multimodal

Las características visuales obtenidas mediante EfficientNet y las características generadas por la red de metadatos se concatenan para formar un único vector de entrada al clasificador final.

El clasificador está formado por capas totalmente conectadas con activación ReLU y una capa de salida con función Sigmoid para realizar la clasificación binaria.

- Entrenamiento del modelo

El entrenamiento se realizó utilizando:

- Función de pérdida BCELoss.
- Optimizador Adam.
- Learning rate de 0.0001.
- Regularización mediante weight_decay.
- Dropout como técnica para reducir el overfitting.

Además, durante el preprocesamiento de imágenes se aplicaron técnicas de Data Augmentation mediante:

- RandomHorizontalFlip.
- RandomRotation.

Estas transformaciones permiten mejorar la capacidad de generalización del modelo.

- Evaluación

Una vez finalizado el entrenamiento, el modelo fue evaluado utilizando el conjunto de prueba.

Las métricas empleadas fueron:

- Accuracy
- Precision
- Recall
- F1-Score

Estas métricas permiten evaluar el rendimiento del clasificador desde distintos puntos de vista, especialmente cuando se trata de una clasificación binaria.

- Conclusiones

Los resultados obtenidos muestran que la combinación de información visual y metadatos permite construir un modelo capaz de predecir el nivel de engagement de un POI.

El uso de Transfer Learning mediante EfficientNet facilita la extracción de características relevantes sin necesidad de entrenar una red convolucional desde cero. Asimismo, la incorporación de metadatos complementa la información visual y mejora la capacidad predictiva del modelo.

Como posibles mejoras futuras podrían incorporarse más variables del conjunto de datos, entrenar el modelo mediante DataLoader para optimizar el rendimiento y realizar un ajuste más exhaustivo de los hiperparámetros.